1 立论依据

项目的研究背景及意义

随着机器人导航、增强现实及物联网技术的进步，室内环境的精准感知和定位需求日益提升。当前主流的**视觉感知技术**易受光照、透明物体、无纹理表面及视距遮挡的影响，存在明显局限。相比之下，**声学感知技术**利用声波传播特性，能有效克服**非视距**环境下的视觉局限，具备更强的鲁棒性。近年来，基于**回声定位**的声学环境感知方法在机器人导航和**室内**轮廓估计中展现出应用潜力，但在复杂室内场景下面临**多径干扰、非视距传播**及**动态环境适应性不足**等问题，制约了其实用化。为此，本项目提出一种融合视觉信息与声学回声的室内环境轮廓估计**方法与系统**，旨在突破现有技术在复杂环境下的局限，实现对室内空间结构的高精度感知。该研究将推动多模态融合感知技术的发展，提升机器人导航的环境适应能力，并促进具身智能机器人的环境轮廓重建应用，具有重要的理论意义和实际应用价值。

国内外研究现状

国外研究方面，学者们在声音感知环境空间轮廓领域起步较早，并取得了较为丰富的研究成果，研究方向主要集中在声学环境的**结构揭示**和**地图重建**两个方面。Hwang 等[1]提出了基于超声回波的高分辨率三维图像重建模型（Bat-G），通过发送 20kHz-120kHz 的 Chirp 信号，成功实现高分辨率的声成像，如图 1 所示；Irie 等人[2]则提出了融合多种声学特征的回声深度估计模型，通过扬声器发送 16kHz 的 Chirp 信号进行深度预测；Christensen 等人[3]研制的 BatVision 系统，利用共址的扬声器和麦克风发送 20Hz-20kHz 的 Chirp 信号进行空间布局估计，并开发了 U-Net 深度估计模型应用于机器人平台[4]；Tracy 等人[5]开发了基于四声道麦克风的全景深度估计模型(CatChatter)；Wilson 等人[6]则以智能手机为基础，发送 63Hz-16kHz 的宽频带声音，并结合相机记录，提出了视听融合的模型(EchoCNN-AV)；Gao 等人[7]在仿真环境中实现了视听特征融合的场景深度估计模型(VisualEchoes)；Zhang 等人[8]进一步开发了基于双目视觉和双耳回声的深度估计模型(StereoEchoes)。上述研究虽然取得一定成果，但在强多径干扰与动态非视距环境中仍面临**精度和鲁棒性不足**的问题。

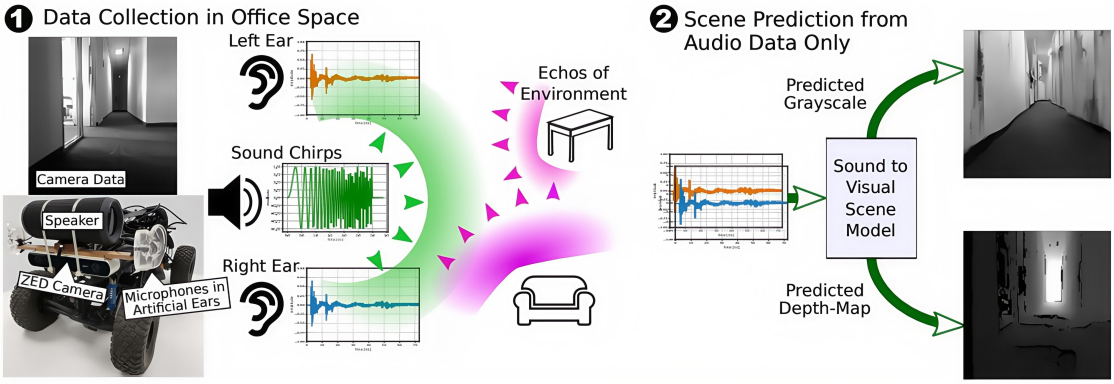

图 1 基于超声回波的高分辨率三维图像重建[1]

国内研究方面，声音环境感知的研究主要围绕**室内空间轮廓的重构与定位**展开，其中无源轮廓估计通过环境中的声源进行房间结构感知[9]，而有源轮廓估计则通过主动发送声音并接收回波实现室内轮廓估计[10]。具体研究中，Song 等人[11]利用智能手机发送 16kHz-22kHz 的 Chirp 信号实现了房间轮廓估计；Zhou 等人[12]则采用 16kHz-24kHz 的 Chirp 信号，基于图优化方法实现了较高精度的房间轮廓估计，如图 2 所示；Pu 等人利用广义互相关特征与图像的动态特征融合策略，在 Replica 数据集上实现了室内场景单目深度估计的改进[13]；Ma 等人通过视听融合耦合坐标自注意的方法，在 Replica 和 Matterport3D 数据集上实现了单目深度估计的优化[14]；Zhang 等人利用关键区域增强与双向语义引导的视听定位模型，在 Flickr-SoundNet 和 VGG-Sound 数据集上实现了声源物体的精确定位[15]；Tong 等人探索了多径效应影响下的 UTDoA 优化算法，实现了更高精度的无线定位平台[16]。然而，目前国内研究多关注单一的声学模态，视听融合方面的研究相对较少，且多集中在简单场景和单一声学模态的应用，尚未有效解决**强多径传播**和**非视距环境**下的精准感知问题，鲁棒性尚需提高。

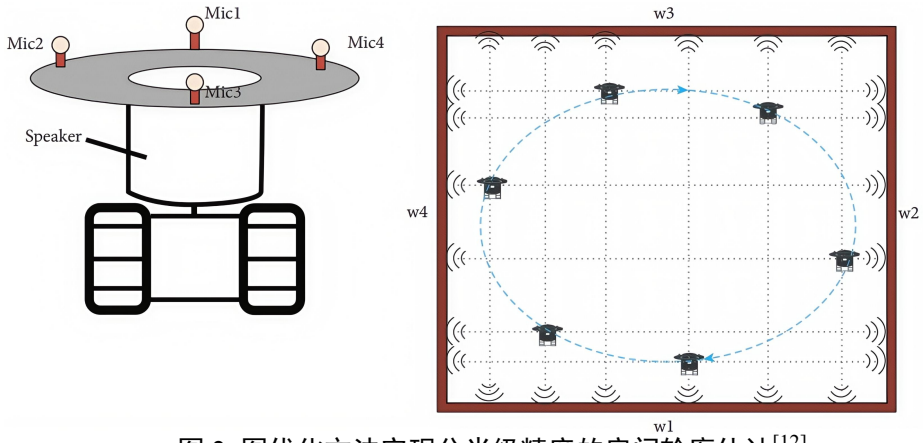

图 2 图优化方法实现分米级精度的房间轮廓估计[12]

调研发现，当前的研究已经从纯回声和视听角度进行了环境轮廓重建，但面向“**寻声导航**”等**与人共融**任务时，其还存在复杂声场干扰下的环境感知失真挑战：**强多径效应(环境布局)、非视距传播(物体遮挡)、多普勒效应(声源/接收器移动)等引起声波混叠、声学特征漂移**，造成现有方法难以满足对非视距区域的空间结构感知需求。

立项目的

针对上述国内外研究中存在的不足，本项目提出研究一种融合视觉与声学回声信息的室内环境轮廓估计**方法与系统**。具体而言，面向具身智能环境机器人的环境轮廓重建，本项目针对现有室内轮廓重建方法缺陷，并设计视听数据采集相关**机械结构与硬件系统**，实现主动声下对复杂室内轮廓进行重构，**突破**传统技术在多强径效应和非视距环境感知的**瓶颈问题**，进一步提升**室内**空间感知技术的精度和鲁棒性。

参考文献

[1] Hwang G, Seohyeon K, *et al.* Bat-G net: Bat-inspired high-resolution 3d image reconstruction using ultrasonic echoes[C]. *International Conference on Neural Information Processing Systems,* 2019: 3720-3731.

[2] Irie G, Shibata T, *et al*. Co-attention-guided bilinear model for echo-based depth estimation[C]. *International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2022: 4648-4652.

[3] Christensen J, Hornauer S, *et al.* BatVision: Learning to see 3D spatial layout with two ears[C]. *International Conference on Robotics and Automation (ICRA)*, 2020: 1581-1587.

[4] Brunetto A, Hornauer S, *et al.* The audio-visual BatVision dataset for research on sight and sound[C]. *International Conference on Intelligent Robots and Systems (IROS)*, 2023: 1-8.

[5] Tracy E, Kottege N. CatChatter: Acoustic perception for mobile robots[J]. *IEEE Robotics and Automation Letters*, 2021, 6(4): 7209-7216.

[6] Wilson J, Rewkowski N, *et al.* Audio-visual depth and material estimation for robot Navigation[C]. *International Conference on Intelligent Robots and Systems (IROS)*, 2022: 9239-9246.

[7] Gao R, Chen C, *et al.* VisualEchoes: Spatial image representation learning through echolocation[C]. *European Conference on Computer Vision (ECCV)*, 2020: 658-676.

[8] Zhang C, Tian K, *et al.* Stereo depth estimation with echoes[C]. *European Conference on Computer Vision (ECCV)*, 2022: 496–513.

[9] Evers C, Patrick A. Acoustic slam[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing (TASLP), 2018,* 26(9): 1484-1498.

[10] Yeon I, Jeong I, *et al.* EchoScan: Scanning complex room geometries via acoustic echoes[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing (TASLP)*, 2024, 32: 4768-4782.

[11] Song X, Wang M, *et al.* Auditory scene analysis-based feature extraction for indoor subarea localization using smartphones[J]. *IEEE Sensors Journal*, 2019, 19(15): 6309-6316.

[12] Zhou Z, Zhang G, *et al.* A graph optimization-based acoustic SLAM edge computing system offering centimeter-level mapping services with reflector recognition capability[J]. *Security and Communication Networks*, 2021: 9126833.

[13] Pu J. Research on monocular depth estimation with audio-visual fusion in indoor environments[D]. *Jiangxi University of Science and Technology*, 2024. DOI:

10.27176/d.cnki.gnfyc.2024.000993.

[14]Ma C, Pu J, Xu C, et al. Monocular depth estimation with audio-visual fusion and coupled coordinate self-attention[J/OL]. *Journal of Computer-Aided Design & Computer Graphics*, 1-12 [2025-03-20].

[15]Zhang J, Xu X, Xie J, et al. Audio-visual localization with key region enhancement and bidirectional semantic guidance[J/OL]. *Computer Engineering and Applications*, 1-11 [2025-03-20].

[16]Tong R, Xie G, Cheng X, et al. Research on UTDoA optimization algorithm under the influence of multipath effects[J]. *Digital Communication World*, 2025, (02): 61-63.

2 研究目标、研究内容和拟解决的关键（技术）问题

本文主要**研究目标、研究内容**和**拟解决关键（技术）问题**如图 3 所示。

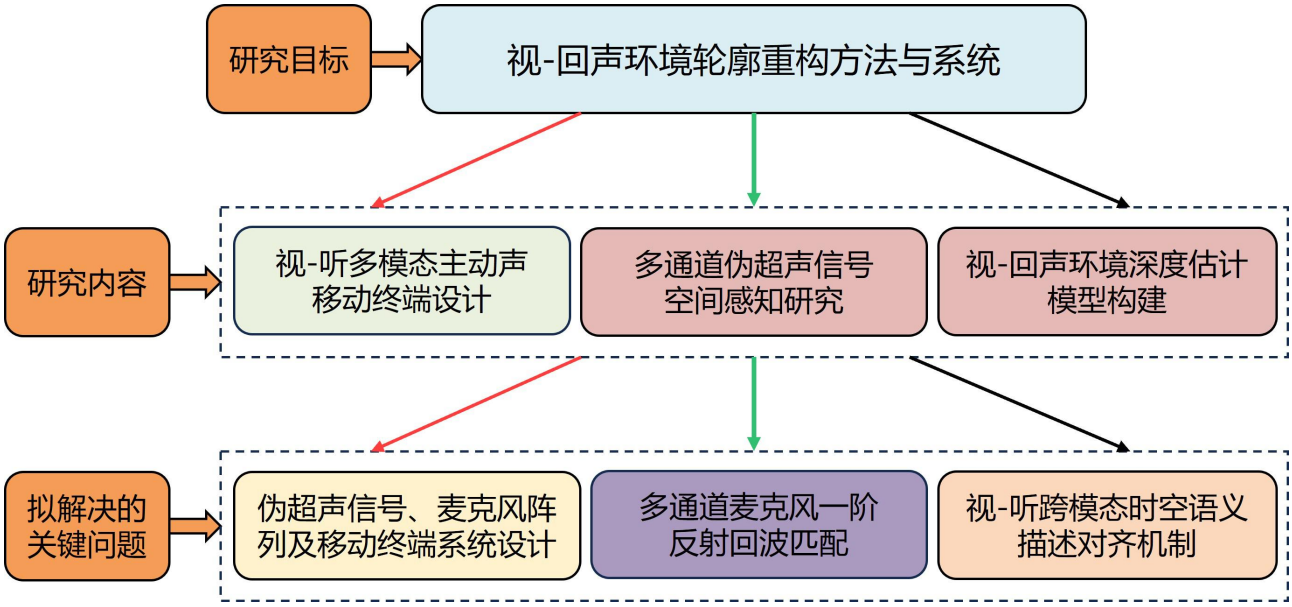

图 3 本项目研究目标、研究内容以及拟解决的关键问题示意图

研究目标

本项目针对复杂室内环境感知的瓶颈问题，提出**视–回声环境轮廓重构方法与系统**。通过设计配备伪超声声源和麦克风阵列的移动终端，收发伪超声信号和采集室内图像；解决“**回波标记**”（Echo Labelling Problem，ELP）问题，实现对室内复杂环境精细感知；开发视-回声深度估计模型，让视觉和声音感知技术优势互补，最终实现对真实室内环境的轮廓构建。

研究内容

为实现复杂非视距动态场景下的高精度环境深度估计和房间轮廓重构，为机器人导航提

供全局拓扑信息，提升室内感知技术的进度和鲁棒性，本次研究主要从以下三个方面进行：a) **视-听多模态主动声移动终端设计**：开展本项目需要可收发伪超声信号和采集室内图像的设备作为项目开展的硬件系统基础；b)**多通道伪超声信号空间感知研究**：为了解决视觉感知非视距等缺陷，需要探究选取何种声源信号，以及如何分析获得的声学信息来理解移动终端所处的环境结构；c)**视-回声环境深度估计模型构建**：获取到室内环境中视觉和回声信息后，需要进一步构建环境深度模型来为最终的室内环境轮廓重构做铺垫。

拟解决的关键（技术）问题

针对提出的研究目标和研究内容，本项目拟解决的关键（技术）如下：1）**伪超声信号、麦克风阵列和移动终端系统设计**：选取何种信号，麦克风的数量及排列方式及移动终端的设计很大程度上会影响对室内空间的感知；2）**多通道麦克风一阶反射回波匹配**：对于多通道麦克风，能否从回波信号中找出低阶回波脉冲并将其标记到对应的反射体上是实现房间形状估计的关键；3）**视-听跨模态时空语义描述对齐机制**：视觉与声学信号在时空特征中差异较大，二者模态间存在明显差异并在特征表达上不一致。研究视-听跨模态语义对齐机制对于我们后续开发视回声环境深度估计模型有重要意义。

3 本课题的特色和主要创新点

（1） 视听跨模态时空语义描述对齐机制

本设计提出了一种创新的**视听跨模态时空语义描述对齐机制**与**端到端的视回声环境深度估计方法**，旨在突破传统技术在复杂环境感知中的**瓶颈问题**。首先，针对传统跨模态学习中视觉和听觉信息对齐的局限性，本设计引入了多层次的时空注意力机制和语义嵌入网络，实现了视听信息在时间和空间维度上的精细化对齐。这种机制不仅克服了单一维度对齐导致的信息丢失或语义不匹配问题，还通过视觉和听觉的**互补机制**，提升了系统在非视距区域和复杂环境中的感知能力。视觉信息可以辅助听觉判断障碍物种类，而在光线不足或非视距情况下，听觉信息则能够辅助视觉进行感知，从而显著增强了系统的适应性和准确性。结合采用伪超声声源和多通道麦克风共址的移动机器人，能够在混响场景中高效收集伪超声回波数据，为视听跨模态对齐提供高质量的输入信号。

（2） 端到端的视回声环境深度估计方法

传统的环境深度估计方法通常依赖于**单一**的视觉或回声数据，且往往需要分阶段处理，导致计算复杂度高且误差累积严重。特别是在复杂的环境中，单一模态的数据难以提供足够的深度信息，而多模态数据的融合又面临对齐和融合的挑战。本设计通过将**视觉**和**回声**数据进行深度融合，实现了从原始数据到深度图的直接映射，避免了传统方法中的多阶段处理问题。这种深度融合不仅提高了深度估计的**精度**和**鲁棒性**，还显著降低了计算复杂度，特别是在**强多径效应**和**非视距环境**下，能够有效克服传统技术的局限性。

4 拟采取的研究方法、技术路线或研究方案

本项目拟采取的**研究方法、技术路线**和**研究方案**总体框图如图 4 所示。

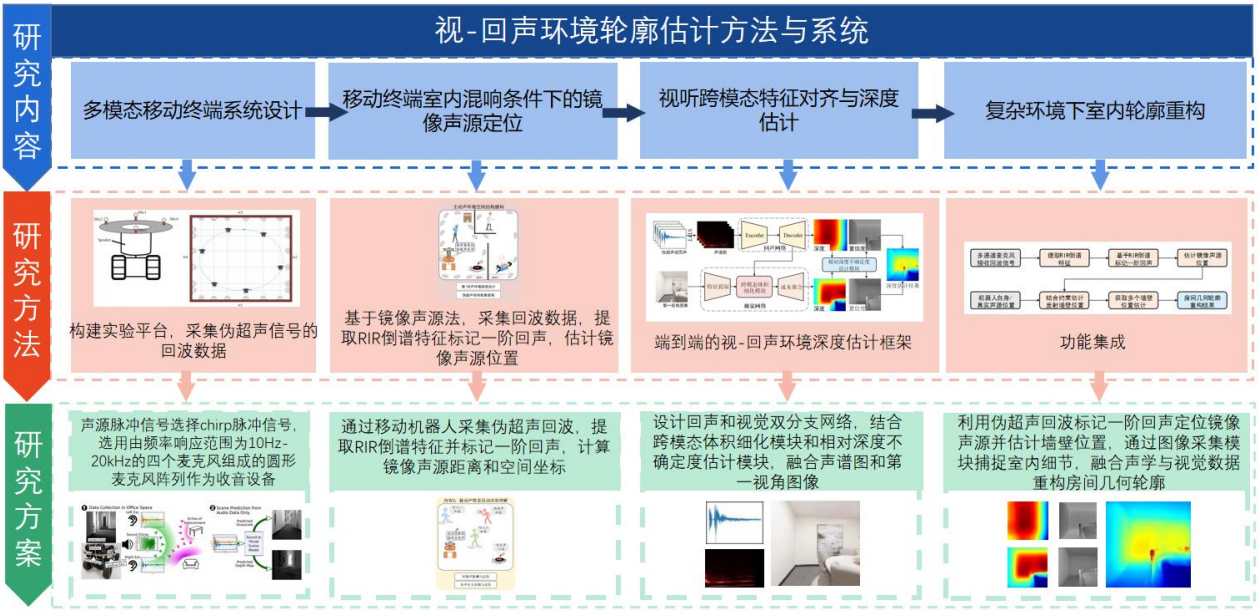

图 4 本项目研究目标、研究内容以及拟解决的关键问题总体框图

具体技术路线：

（1） 多模态移动终端系统设计

为采集室内环境轮廓的深度和视觉信息，本项目需要可**收发伪超声信号**和**采集图像**的移动平台或终端，该系统最重要的伪超声**声源信号的选择**和**麦克风阵列设计**。本项目移动终端声源脉冲信号选择的是 chirp 脉冲信号，采用 chirp 信号有诸多优势：**优良自相关特性提升测距分辨率与接收灵敏度；多普勒效应抗性及多径信号分离能力；强干扰特性，保障多麦克风阵列的可靠信号接收；人耳对此频段声音信号不敏感，不会造成听觉干扰。**本项目通过全向扬声器向环境间断发送伪超声信号(16kHz-20kHz 频段、0.2s 的 Chirp 脉冲信号)。为同时接收伪超声回波信号和环境中的自然声音，本项目选用由频率响应范围为 10Hz-20kHz 的**四个麦克风**组成的圆形麦克风阵列作为收音设备。

Chirp 脉冲信号属于线性调频信号，其频率随时间线性地增大或减小：

$$s(t)=\sin\left(2\pi\left(f_0+\frac{f_1-f_0}{2T}t\right)t\right),0\le t\le T \tag{1}$$

式中，T 表示信号时长，f_0 为下限频率，f_1 为上限频率。

对于波长范围 1.70cm-2.13cm 的伪超声(16kHz-20kHz)，其波长小于绝大多数的室内物品，此时声波基本遵循几何反射定律，即室内常规壁面、顶面以及反射平面等都会依照倾角按几何定律反射，不发生折射，扩散可忽略。

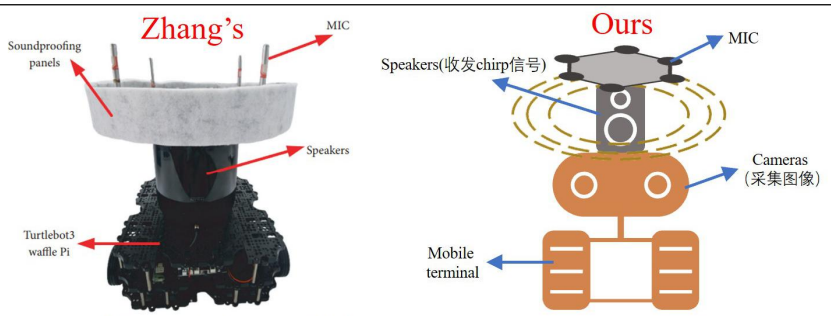

(a) Zhang等人设计的移动终端系统实物图　(b) 本项目拟设计的移动终端系统示意图

图 5 多模态移动终端示意图

（2） 移动终端室内混响条件下的镜像声源定位

基于上述声源和麦克风阵列的选择和设计，本项目采用几何声学模型(**镜像声源法**)对室内伪超声传播进行建模。**镜像声源法**，通常利用**真实声源**与**镜像声源**的位置约束关系来估计房间几何轮廓。但是，由于二阶及以上的声回波信号要经过二次及以上的墙壁反射，通常信号较弱，信号的到达时间难以全部获取，对于二阶及以上的镜像声源位置估计难度较大。因此，本项目采用**一阶回波**信息来估计镜像声源位置。

项目采用伪超声声源和多通道麦克风共址的移动机器人来收集伪超声回波(如图 5 所示)，真实声源位置即为机器人自身位置。对于此，本项目提出基于一阶回声标记的混响场景伪超声房间轮廓重构方法，如图 6 所示。该方法利用多通道麦克风接收回波(可通过室内脉冲响应(Room Impulse Responses, RIR)进行描述)，通过提取 RIR 倒谱特征标记一阶回声以估计镜像声源位置，进而结合真实与镜像声源位置约束关系估计反射墙壁位置，最终获取多个墙壁位置估计结果实现房间几何轮廓重构。其中，定位镜像声源则是该方法实现定位房间反射体的必要基础，而能否从混响信号中**标记出一阶反射声**成为估计镜像声源的**关键前提**。

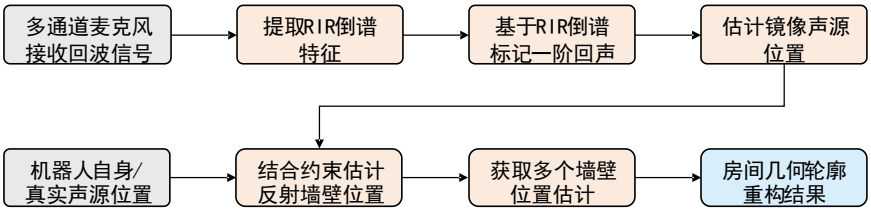

图 6 基于一阶回声标记的混响场景伪超声房间轮廓重构方法流程

麦克风阵列所接收的信号包含直达声与反射声，其特性可用室内脉冲响应描述，由直达声和反射声组成：

$$h_j(t)=\sum_i \alpha_i \delta\left(t-\tau_i\right)+\varepsilon(t) \tag{2}$$

其中，α_i 代表接收第 i 个回波脉冲的幅度，其大小受反射墙壁的吸声系数以及镜像声源到麦克风 r_j 的距离影响；τ_i 是对应第 i 个回波脉冲的到达时间，与镜像源到麦克风 r_j 的距离成正比；$\varepsilon(t)$ 表示噪声。

为基于 RIR 倒谱特征进行一阶回声标记，需从室内脉冲响应中提取 RIR 倒谱特征。首先，

针对每个脉冲，计算其平均能量特征：

$$r_{i,j,k}=\sqrt{\frac{1}{2L+1}\sum_{n=\tau_{i,j,k}-L}^{n=\tau_{i,j,k}+L}h_{i,j}(n)^2} \tag{3}$$

该特征反映了脉冲能量在时间上的分布情况，同时计算时延特征：

$$t_{i,j,k}=\tau_{i,j,k}\cdot c \tag{4}$$

其中 c 为声音在空气中的传播速度，时延特征体现脉冲传播的时间延迟信息。

接着，对这两个特征分别进行 log 运算，得到对数能量向量和对数时延向量 $q_{\{i,k\}}$，通过对数运算能够增强特征的辨识度和稳定性。然后，对相关矩阵进行主成分分析运算，选取主成分分量组成 RIR 倒谱 d_{h_k} 。

得到 RIR 倒谱之后，开始进行**一阶回声标记**。首先进行倒谱分析，在 RIR 倒谱中，直达声和一阶回声表现为明显的峰值。一阶回声对应的是直达声之后的第一个显著峰值。接着，进行峰值检测，使用峰值检测算法（如局部最大值检测）识别倒谱中的峰值，一阶回声的峰值通常位于较低的时间延迟区域。最后，根据峰值的位置和幅度，标记一阶回声的时间延迟和相对强度。

为了进行镜像声源定位，根据一阶回声的时间延迟 τ_i 和声音传播速度 c，计算镜像声源到麦克风的距离：

$$d_i=c\cdot\tau_i \tag{5}$$

最后，结合麦克风阵列的几何位置，估计镜像声源的**空间坐标**。

（3） 视听跨模态特征对齐与深度估计

机器人视觉感知在**良好光照条件**下和**具有表面纹理物体**上有较好的性能表现，但其在具有开放性与高反射表面的环境要素(如窗户、镜子)和光照不好条件下的感知性能极为受限，而声音信号依靠其反射传播特性可较好地感知障碍物的存在，弥补此缺陷。基于**视-回声**两种信号模式之间的相互关系，本项目提出一个**端到端**的视-回声环境深度估计框架，如图 7 所示。

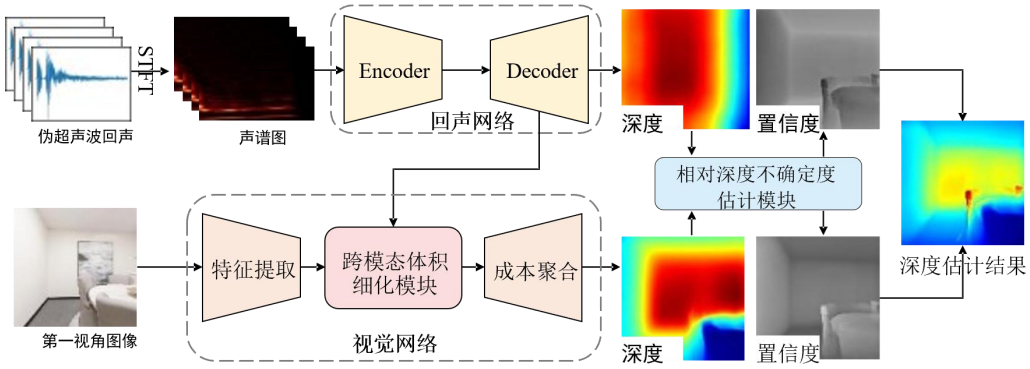

图 7 视回声环境深度估计模型框架

其包含**回声**和**视觉**两个分支网络，用以分别处理声谱图和机器人第一视角图像输入。设计了一个跨模态体积细化模块，用于将音频模态的互补知识转移到特征级的视觉模态上；进一步提出了一种相对深度不确定度估计模块，以基于回声深度估计和成本聚合视觉深度估计，获得**多模态**融合的**像素级深度估计**结果。

（4） 复杂环境下室内轮廓重构

在研究背景中我们提到，主流**视觉感知**技术能直接捕捉**室内环境细节**，但极大程度上受限于室内环境因素，如光照、物体表面纹理等；而**声学感知**技术能有效能有效**克服非视距**环境下视觉局限，但无法捕捉室内环境细节，只能推断如墙壁所处位置。因此，为突破现有技术在复杂环境下的局限，提升机器人导航的环境适应能力，本项目利用声学镜像法来获取室内墙壁位置，同时借助移动终端搭载的图像采集模块来捕捉室内轮廓细节。根据镜像声源的位置和真实声源的位置，计算反射墙壁的法向量和位置。重复上述过程，对多个一阶回声进行标记和镜像声源定位，估计多个反射墙壁的位置。将多个反射墙壁的位置信息整合，借以图像细节辅助，重构房间的几何轮廓。

图 8 复杂环境下室内轮廓重构